

Realistic Image Classification

Project Report

Lutu Adrian-Catalin

Grupa 252

Modele Utilizate:	3
Arhitecturi CNN	3
Arhitecturi CNN residual	13
Optimizer si Loss Function	14
Augmentarea datelor	14
CNN6:.....	15
Tabele CNN6:.....	15
CNN10:.....	16
Tabele CNN10:.....	17
Optimizarea hiperparametrilor	19
Numarul de epoci.....	19
Rata de invatare.....	20
Rezultate notabile	20
Submisii	21
Matrici de confuzie.....	23
KNN	24

Modele Utilizate:

- KNN
- CNN
- CNN residual

Arhitecturi CNN

1. CNN1

- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat de flatten
- Strat dens cu 64 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni, cu functia de activare SoftMax

2. CNN2

- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Flatten
- Strat dens cu 64 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni, cu functia de activare SoftMax

3. CNN3

- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat de flatten
- Strat dens cu 64 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni, cu functia de activare SoftMax

4. CNN4

- Strat convolutional cu 32 de filtre 5x5, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 5x5, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat de flatten

- Strat dens cu 64 neuroni, cu functia de activare ReLU
 - Strat dens cu 3 neuroni, cu functia de activare SoftMax
5. CNN5
- Strat convolutional cu 64 de filtre 5x5, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Strat convolutional cu 64 de filtre 5x5, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Strat de flatten
 - Strat dens cu 64 neuroni, cu functia de activare ReLU
 - Strat dens cu 3 neuroni, cu functia de activare SoftMax
6. CNN6
- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Dropout 0.5
 - Strat de flatten
 - Strat dens cu 64 neuroni, cu functia de activare ReLU
 - Strat dens cu 3 neuroni
7. CNN7
- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Dropout 0.5
 - Strat de flatten
 - Strat dens cu 64 neuroni, cu functia de activare ReLU
 - Strat dens cu 3 neuroni
8. CNN8
- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2
 - Dropout 0.5
 - Strat de flatten
 - Strat dens cu 128 neuroni, cu functia de activare ReLU
 - Strat dens cu 3 neuroni
9. CNN9
- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
 - Strat de max pool de marime 2x2

- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 256 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

10. CNN10

- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 512 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

11. CNN11

- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 128 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 128 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

12. CNN12

- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 128 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 128 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

13. CNN13

- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 128 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 512 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

14. CNN14

- Strat convolutional cu 16 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 128 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 128 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

15. CNN15

- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 128 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 256 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

16. CNN16

- Strat convolutional cu 10 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 30 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 60 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 120 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 128 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

17. CNN17

- Strat convolutional cu 20 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 30 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 60 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Strat convolutional cu 120 de filtre 3x3, cu functia de activare ReLU
- Strat de max pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 128 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

18. CNN18

- Strat convolutional cu 16 de filtre 3x3, cu functia de activare ReLU
- Strat de avg pool de marime 2x2
- Strat convolutional cu 32 de filtre 3x3, cu functia de activare ReLU
- Strat de avg pool de marime 2x2
- Strat convolutional cu 64 de filtre 3x3, cu functia de activare ReLU
- Strat de avg pool de marime 2x2
- Strat convolutional cu 128 de filtre 3x3, cu functia de activare ReLU
- Strat de avg pool de marime 2x2
- Dropout 0.5
- Strat de flatten
- Strat dens cu 128 neuroni, cu functia de activare ReLU
- Strat dens cu 3 neuroni

19. CNN19

- Strat convolution cu 16 filtre 3x3, cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, stride de 2 ,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,cu functia de activare ReLU

- Strat avg pool global
- Dropout 0.5
- Strat de flatten
- Strat dens cu 3 neuroni

20. CNN20

- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat avg pool global
- Dropout 0.5
- Strat de flatten
- Strat dens cu 3 neuroni

21. CNN21

- Strat convolution cu 16 filtre 5x5,batch normalization ,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat avg pool global
- Dropout 0.5
- Strat de flatten
- Strat dens cu 3 neuroni

22. CNN22

- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU

- Strat convolutional cu 256 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 512 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat de avg pooling global
- Dropout 0.5
- Flatten
- Dense 3

23. CNN23

- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 512 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat de avg pooling global
- Dropout 0.5
- Flatten
- Dense 3

24. CNN24

- Strat convolution cu 32 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolution cu 32 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 512 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 1024 de filtre 3x3,batch normalization,cu functia de activare ReLU

- Strat de avg pooling global
- Dropout 0.5
- Flatten
- Dense 3

25. CNN25

- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat de avg pooling global
- Dropout 0.5
- Flatten
- Dense 3

26. CNN26

- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolution cu 16 filtre 3x3,batch normalization ,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 512 de filtre 3x3, stride de 2,batch normalization,cu functia de activare ReLU
- Strat de avg pooling global
- Dropout 0.5

- Flatten
- Dense 3

27. CNN27

- Strat convolutional cu 32 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 32 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, stride de 2, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3, stride de 2, batch normalization, cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3, batch normalization, cu functia de activare ReLU

- Strat convolutional cu 256 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat de avg pooling global
- Dropout 0.5
- Flatten
- Strat dens cu 3 neuroni

28. CNN28

- Strat convolutional cu 64 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 64 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 128 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 256 de filtre 3x3,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 512 de filtre 3x3, stride de 2 ,batch normalization,cu functia de activare ReLU
- Strat convolutional cu 512 de filtre 3x3,batch normalization,cu functia de activare ReLU

- Strat convolutional cu 512 de filtre 3x3, batch normalization, cu functia de activare ReLU
- Strat de avg pooling global
- Dropout 0.5
- Flatten
- Strat dens cu 3 neuroni

Arhitecturi CNN residual

Blocul residual:

- Strat convolution cu numar specificat de filtre de marime 3x3, stride de 1 sau 2 in functie de valoarea booleana a lui pool (daca pool este True stride este 2), padding = 1, batch normalization, cu functia de activare ReLU
- Strat convolutional cu numar specificat de filtre de marime 3x3, stride de 1, padding = 1, batch normalization, cu functia de activare ReLU
- Daca proj este True atunci avem un strat convolutional cu numar specificat de filtre de marime 1x1, stride de 1 sau 2 (daca pool este True stride este 2), padding = 1, pentru a schimba numarul de canale ale inputului

1. ResNetDIY

- Bloc residual cu 32 de filtre si proj setat ca True
- Bloc residual cu 32 de filtre
- Bloc residual cu 32 de filtre
- Bloc residual cu 64 de filtre, proj setat ca True si pool setat ca True
- Bloc residual cu 64 de filtre
- Bloc residual cu 64 de filtre
- Bloc residual cu 128 de filtre, proj setat ca True si pool setat ca True
- Bloc residual cu 128 de filtre
- Bloc residual cu 128 de filtre
- Bloc residual cu 256 de filtre, proj setat ca True si pool setat ca True
- Bloc residual cu 256 de filtre
- Bloc residual cu 256 de filtre
- Strat de avg pooling global
- Strat de flatten
- Strat dens cu 3 neuroni

2. ResNetDIY2

- Bloc residual cu 32 de filtre si proj setat ca True
- Bloc residual cu 32 de filtre
- Bloc residual cu 32 de filtre
- Bloc residual cu 64 de filtre, proj setat ca True si pool setat ca True
- Bloc residual cu 64 de filtre
- Bloc residual cu 64 de filtre

- Bloc residual cu 128 de filtre, proj setat ca True si pool setat ca True
 - Bloc residual cu 128 de filtre
 - Bloc residual cu 128 de filtre
 - Bloc residual cu 256 de filtre, proj setat ca True si pool setat ca True
 - Bloc residual cu 256 de filtre
 - Bloc residual cu 256 de filtre
 - Bloc residual cu 512 de filtre, proj setat ca True si pool setat ca True
 - Bloc residual cu 512 de filtre
 - Bloc residual cu 512 de filtre
 - Strat de avg pooling global
 - Strat de flatten
 - Strat dens cu 3 neuroni
3. ResNetDIY3
- Bloc residual cu 32 de filtre si proj setat ca True
 - Bloc residual cu 32 de filtre
 - Bloc residual cu 32 de filtre
 - Bloc residual cu 64 de filtre, proj setat ca True si pool setat ca True
 - Bloc residual cu 64 de filtre
 - Bloc residual cu 64 de filtre
 - Bloc residual cu 128 de filtre, proj setat ca True si pool setat ca True
 - Bloc residual cu 128 de filtre
 - Bloc residual cu 128 de filtre
 - Bloc residual cu 256 de filtre, proj setat ca True si pool setat ca True
 - Bloc residual cu 256 de filtre
 - Bloc residual cu 256 de filtre
 - Strat de avg pooling global
 - Dropout 0.5
 - Strat de flatten
 - Strat dens cu 3 neuroni

Optimizer si Loss Function

Toate retelele au fost antrenate utilizand optimizer-ul Adam si functia de pierdere spare categorical crossentropy.

Augmentarea datelor

Majoritatea testelor pentru diferitele tipuri de augmentare de date au fost efectuate asupra arhitecturilor: CNN6 si CNN10. Pe acestea au fost incercate diverse augmentari, marimea setului de antrenament ajungand intre 21000 si 84000 de poze.

CNN6:

1. 21000 de poze
 - a. Random brightness
 - i. Schimbare de maxim 0.2
 - ii. Schimbare de maxim 0.1
 - iii. Schimbare de maxim 0.5
 - b. Random contrast
 - i. Factor de contrast intre 0.2 si 0.5
 - ii. Factor de contrast intre 0.2 si 0.4
 - c. Random Hue
 - i. Factor intre 0.2 si 0.4
2. 31500 de poze
 - a. Flip up down + flip left right
3. 42000 de poze
 - a. Rotatie de 90 de grade + Rotatie de 180 de grade + Rotatie de 270 de grade

Tabele CNN6:

Totale testele au fost efectuate antrenand pentru 5 epoci cu rata de invatare de 0.001 si un batch size de 64.

Random brightness:

Eticheta lista\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
i	54%	73%
ii	58%	86%
iii	53.7%	78%

Random Contrast:

Eticheta lista\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
i	53%	66%
ii	56%	58%

Random Hue:

Eticheta lista\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
i	60%	82%

Flip up down + Flip left right:

Numar de epoci\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
5	62.3%	66.2%

Rotatie de 90 de grade + Rotatie de 180 de grade + Rotatie de 270 de grade

Numar de epoci\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
5	60%	64%
10	65%	70%
15	64%	75.9%

CNN10:

1. 21000 de poze
 - a. Rotatie de 90 de grade
 - b. Rotatie de 180 de grade
 - c. Rotatie de 270 de grade
 - d. Rotatie de 90 de grade, pe care aplic Flip up down
 - e. Rotatie de 180 de grade, pe care aplic Flip up down
 - f. Rotatie de 270 de grade, pe care aplic Flip up down
2. 31500 de poze
 - a. Rotatie de 90 de grade + Rotatie de 180 de grade
 - b. Rotatie de 90 de grade + Rotatie de 270 de grade
 - c. Rotatie de 180 de grade + Rotatie de 270 de grade
 - d. Rotatie de 90 de grade + Rotatie de 180 de grade, pe care aplic flip up down
 - e. Rotatie de 90 de grade + Rotatie de 270 de grade, pe care aplic flip up down
 - f. Rotatie de 180 de grade + Rotatie de 270 de grade, pe care aplic flip up down
3. 42000 de poze
 - a. Rotatie de 90 de grade + Rotatie de 180 de grade + Rotatie de 270 de grade

- b. Rotatie de 90 de grade + Rotatie de 180 de grade + Rotatie de 270 de grade, pe care aplic flip up down
- 4. 63000 de poze
 - a. Rotatie de 90 de grade + Rotatie de 180 de grade + Rotatie de 270 de grade + Flip up down + Flip left right
- 5. 73500 de poze
 - a. Rotatie de 90 de grade + Rotatie de 180 de grade + Rotatie de 270 de grade + Flip up down + Flip left right + Rotatii de 90 de grade pe care aplic Flip up down
- 6. 84000 de poze
 - a. Rotatie de 90 de grade + Rotatie de 180 de grade + Rotatie de 270 de grade + Flip up down + Flip left right + Rotatie de 90 de grade, pe care aplic Flip up down + Rotatie de 270 de grade, pe care aplic Flip up down

Tabele CNN10:

Toate testele sunt efectuate antrenand 5 epoci, cu o rata de invatare de 0.001 si un batch size de 64.

Seturi de antrenare cu 10500 de poze(fara augmentare):

Eticheta\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
Fara augmentare	59%	60%

Seturi de antrenare cu 21000 de poze:

Eticheta\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
a	52%	64%
b	62.2%	62.6%
c	59%	62.3%
d	53%	61%
e	59%	62%
f	61%	63%

Seturi de antrenare cu 31500 de poze:

Eticheta\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
a	64%	63.2%
b	63%	64%
c	62%	64%
d	60%	65.4%
e	60.8%	64%
f	64%	64.8%

Seturi de antrenare cu 42000 de poze:

Eticheta\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
a	66.5%	65.5%
b	62%	66%

Seturi de antrenare cu 63000 de poze:

Eticheta\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
a	67.3%	74.6%

Seturi de antrenare cu 73500 de poze:

Eticheta\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
a	62.9%	68.8%

Seturi de antrenare cu 84000 de poze:

Eticheta\ Acuratete	Acuratete pe setul de validare	Acuratete pe setul de antrenare
a	66.27%	68.26%

Astfel din aceste teste am concluzionat ca cea mai avantajoasa metoda de augmentare este adaugarea tuturor rotatiilor la unghiuri de 90 de grade, setul de antrenare ajungand la 42000 de poze. Acesta ofera cea mai mare crestere de performanta, iar diferenta dintre acuratetea pe setul de validare si acuratetea pe setul de antrenare este foarte mica. Deasemenea timpul de antrenare ramane relativ mic fata de alte seturi de antrenare mai mari, precum cel cu 84000 sau 63000 de poze, ce au avut acuratetea pe setul de validare mai mare

sau cel putin egala. Din aceste motive am decis sa continui testarea si experimentarea utilizand aceasta tehnica de augmentare.

Optimizarea hiperparametrilor

Numarul de epoci

Pentru a optimiza numarul de epoci am incercat diverse valori pentru fiecare arhitectura, considerand ca optim numarul de epoci ce a produs acuratetea maxima pe setul de validare.

Testele au fost efectuate cu o rata de invatare de 0.001 si un batch size de 64.

CNN27:

Numar de epoci	Acuratete pe setul de validare
10	72.3%
20	74.5%
25	75.63%

ResNetDIY:

Numar de epoci	Acuratete pe setul de validare
25	76.63%
30	73.80%
50	72.27%

ResNetDIY2:

Numar de epoci	Acuratete pe setul de validare
25	71.20%
30	65.54%

50	73.27%
----	--------

Din cauza timpului de antrenare indelungat pentru rețelele residuale numărul de teste nu este prea mare, astfel rezultatele sunt puternic influentate de starea initiala aleatorie.

Rata de invatare

Similar cu optimizarea numărului epoci, am încercat mai multe valori pentru rata de invatare, dar am obținut rezultate mai slabe decât cu rata de invatare initiala de 0.001, astfel am renunțat destul de repede să mai încerc noi valori.

CNN12:

Testele au fost efectuate pe un set de antrenare de 52500 de imagini ce continea toate rotațiile la unghiuri de 90 de grade și Flip left right, antrenat pentru 10 epoci, cu un batch size de 64.

Rata de invatare\ Acuratete	Acuratete pentru validare	Acuratete pentru antrenare
0.001	69.17%	69.68%
0.0005	68.6%	69.82%
0.0007	68.47%	69.55%
0.0003	66.8%	69.14%
0.0015	65.87%	67.67%
0.002	64.37%	66.09%

Rezultate notabile

În această secțiune voi expune câteva din rezultatele, ce eu le consider notabile, precum arhitectura cu cea mai acuratete sau prima arhitectura ce a depășit 70%, pe care le-am obținut în cadrul acestei competiții pentru câteva din arhitecturile expuse.

Arhitectura\Detalii	Acuratete pe validare	Rata de invatare	Numar de epoci	Batch Size
CNN23	70.8%	0.001	10	64

CNN25	73.5%	0.001	10	64
CNN26	74.93%	0.001	10	64
CNN27	75.63%	0.001	25	64
ResNetDIY	76.63%	0.001	25	64

Submisii

1. Submisia aduna confidence-urile retelelor, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,3,4,5 din script-ul Predict).
2. Submisia consta in antrenarea unui svm folosind vectorii de confidence al retelelor ca si date de antrenare(Contine modelele cu indicii 1,2,3,4,5 din script-ul Predict).
3. Submisia foloseste label-ul date de fiecare retea ca si vot, clasa cu cele mai multe voturi este considerata label(Contine modelele cu indicii 1,2,3,4,5 din script-ul Predict).
4. Submisia aduna confidence-urile retelelor, iar clasa este data de maximul acestora(Contine modelele cu indicii 1.4.5.6 din script-ul Predict)
5. Submisia consta in label-urile date de modelul cu indicele 6
6. Submisia aduna confidence-urile retelelor, iar clasa data de maximul acestora(Contine modelele cu indicii 1.2.5.6.7.8 din script-ul Predict)
7. Submisia aduna confidence-urile retelelor inmultite cu $\text{model_acc}/\text{sum}(\text{model_acc})$, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,5,6,7,8 din script-ul Predict)
8. Submisia aduna confidence-urile retelelor inmultite cu $\text{model_acc}/\text{sum}(\text{model_acc})$, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,3,5,6,8,9,10,11 din script-ul Predict)
9. Submisia aduna confidence-urile retelelor inmultite cu $\text{model_acc}/\text{sum}(\text{model_acc})$, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,5,6,9,12,14 din script-ul Predict)
10. Submisia aduna confidence-urile retelelor inmultite cu $\text{model_acc}/\text{sum}(\text{model_acc})$, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,3,5,6,9,10,11 din script-ul Predict)
11. Submisia aduna confidence-urile retelelor inmultite cu $\text{model_acc}/\text{sum}(\text{model_acc})$, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,5,6,8,9,10,12,15,16,19 din script-ul Predict)
12. Submisia aduna confidence-urile retelelor inmultite cu $\text{model_acc}/\text{sum}(\text{model_acc})$, iar clasa este data de maximul acestora(Contine modelul cu indicii 2,4,5,6 din script-ul Predict2)
13. Submisia aduna confidence-urile retelelor, iar clasa este data de maximul acestora(Contine modelele cu indicii 2,4,5,6,7 din script-ul Predict2)

14. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,4,7,10,11,12 din script-ul Predict2)
15. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,4,5,6,7,10,12 din script-ul Predict2)
16. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 2,5,6,7,10,12 din script-ul Predict2)
17. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,4,5,6,7,9,12,13,15)
18. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,4,5,6,7,9,10,11,12,15 din script-ul Predict2)
19. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,3,5,6,7,9,10,12,13,15 din script-ul Predict2)
20. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,3,4,5,10,12,13,16 din script-ul Predict2)
21. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,4,5,6,7,10,12,13,16 din script-ul Predict2)
22. Submisia aduna confidence-urile retelelor inmultite cu `model_acc/sum(model_acc)`, iar clasa este data de maximul acestora(Contine modelele cu indicii 1,2,3,4,5,6,7,10,12,13,15,16 din script-ul Predict2)

Pentru a face o predictie aleg modelul ce depasesc un anumit prag de acuratete minima (71% pentru script-ul Predict si 73.96% pentru script-ul Predict2), iar apoi trec prin toate combinarile posibile si o selectez pe cea cu acuratetea cea mai mare pe setul de validare.

Submisie\Acurateti	Acuratete pe validare	Acuratete publica pe Kaggle	Acuratete privata pe Kaggle
1	76.2%	76.977%	77.33%
2	76.7%	41.51%	40.82%
3	75.5%	76.71%	77.15%
4	76.93%	76.266%	77.214%
5	74.9%	75.288%	75.31%

6	76.9%	77.6%	77.77%
7	76.93%	77.68%	77.77%
8	77.43%	77.6%	77.95%
9	77.7%	76.88%	77.86%
10	77.43%	77.6%	77.629%
11	77.93%	77.6%	77.9855%
12	78.1%	77.42%	77.748%
13	77.66%	77.24%	77.92%
14	78.23%	78.488%	78.84%
15	78.2%	77.86%	78.66%
16	78.16%	77.955%	78.725%
17	78.53%	78.4%	79.111%
18	78.53%	78.488%	78.607%
19	78.5%	78.04%	78.577%
20	79.16%	79.377%	79.081%
21	79.06%	79.377%	79.051%
22	79.03%	79.288%	78.992%

Matrici de confuzie

Submisia 20:

Actual\Predicted	0	1	2
0	939	9	52
1	15	802	183
2	30	336	634

Submisia 21:

Actual\Predicted	0	1	2
0	940	8	52
1	15	801	184
2	33	336	631

Submisia 17:

Actual\Predicted	0	1	2
0	941	11	48
1	17	798	185
2	40	343	617

Submisia 22:

Actual\Predicted	0	1	2
0	940	10	50
1	15	797	188
2	30	337	633

KNN

Prima incercare pe care am facut-o a fost un model de tipul KNN, ce folosea distanta manhattan. Practic calcula diferenta de culoare dintre pixeli. Pentru un model KNN cu 17 vecini si distanta manhattan am obtinut o acuratete de 46.66%.